

Análise de Dados Aplicada à Experimentação em Engenharia de Software

Trabalho Final - Grupo 1

Caio Batella Filipe Faria Gabriel Augusto João Aguiar José Victor Kaio
Henrique Kayler de Freitas Lucas de Carvalho Pedro Henrique Rodrigo
Diniz Thales Eduardo Vitor Pereira Vitor Rebula

Pontifícia Universidade Católica de Minas Gerais
Engenharia de Software


Junho de 2026

Sumário

- 1 Etapas de Experimentação e Dados
- 2 Fontes de Dados
- 3 Ferramentas de Análise
- 4 Estatística Descritiva
- 5 Testes Estatísticos
- 6 Regressões e Modelagem
- 7 Visualização de Dados - Tipos de Gráficos
- 8 Outros Gráficos
- 9 Grafico Certo vs. Grafico Errado
- 10 Considerações Finais

Etapas de Experimentação e Dados

Segundo **Wohlin et al. (2012)**, a validade científica depende da gestão rigorosa dos dados. Abaixo, ilustramos as etapas usando como exemplo uma pesquisa documental com dados do **Censo Demográfico (IBGE)** sobre saneamento e renda.



Objetivo do Exemplo: Investigar se municípios com maior cobertura de esgoto possuem renda per capita significativamente superior.

1. Coleta de Dados (Data Collection)

Fase de instrumentação e captura das variáveis dependentes e independentes.

Conceito Teórico

- Uso de *instrumentos de medição* automatizados para evitar viés humano.
- Garantia de que a coleta não interfere no ambiente observado.

Aplicação Prática

- **Fonte:** API do SIDRA (IBGE) e DATASUS.
- **Variável Independente:** % de domicílios com rede geral de esgoto por município.
- **Variável Dependente:** Renda domiciliar per capita mensal.
- **Instrumentação:** Script Python (pySIDRA) para extração massiva dos 5.570 municípios, garantindo consistência temporal (Censo 2022).

2. Persistência e Armazenamento

Garantia da rastreabilidade dos dados brutos (*raw data*) para replicabilidade.

Conceito Teórico

- Separação entre dados imutáveis (brutos) e dados processados.
- Documentação de metadados para validade de construto.

Aplicação Prática

- **Raw Zone:** Armazenamento dos arquivos JSON/CSV originais do IBGE em Data Lake (imutáveis).
- **Curated Zone:** Banco PostgreSQL estruturado em tabelas fato (*fact_indicadores*) e dimensão (*dim_municipio*, *dim_regiao*).
- **Governança:** Registro da data de extração e versão do Censo para auditoria futura.

3. Manipulação e Pré-processamento

Etapa de **Redução do Conjunto de Dados** (Wohlin et al., 2012), preparando a base para testes estatísticos.

Conceito Teórico

- Tratamento de *outliers*, ruído e dados faltantes (*missing data*).
- Normalização de escalas para comparação justa.

Aplicação Prática

- **Missing Data:** Exclusão de municípios com sigilo fiscal na renda (dados omitidos pelo IBGE).
- **Outliers:** Identificação de cidades com renda atípica devido a royalties de petróleo (ex: Rio das Ostras/RJ) via Boxplot.
- **Ruído:** Remoção de registros duplicados ou códigos de município inválidos.
- **Normalização:** Cálculo de métricas per capita para comparar municípios de portes populacionais distintos.

4. Análise de Dados

Extração de conclusões via estatística descritiva e inferencial (**Juristo & Moreno, 2013**).

Conceito Teórico

- **Descritiva:** Tendência central e dispersão para entender a distribuição.
- **Inferencial:** Testes de hipótese para validar relações causais ou correlacionais.

Aplicação Prática

- **Descritiva:** Histogramas da distribuição de renda por região (Norte vs. Sudeste).
- **Teste de Hipótese:** Como os dados de renda são assimétricos (não normais), aplica-se o teste não paramétrico **Mann-Whitney U**.
- **Objetivo:** Comparar se a mediana da renda difere significativamente entre municípios com alto ($> 80\%$) e baixo ($< 20\%$) saneamento.
- **Visualização:** Mapas coropléticos (Choropleth) cruzando IDs de saneamento e renda.

Principais Fontes de Dados para ES

Repositórios de código e controle de versão

- **GitHub / GitLab / Bitbucket** - commits, branches, PRs, issues, labels
- **GH Archive** - eventos públicos do GitHub, atualizado a cada hora (BigQuery)
- **GHTorrent** - mirror histórico de eventos do GitHub em banco SQL

Datasets curados de ES

- **PROMISE Repository** - ~20 datasets clássicos (defeitos, esforço)
- **NASA Metrics Data Program** - métricas de projetos da NASA
- **ISBSG** - benchmarking de esforço/custo de projetos

Outras fontes

- **Jira / Bugzilla dumps** - histórico de defeitos e issues
- **Stack Overflow Developer Survey** - perfil e práticas de devs
- **Code Coverage Services** (Coveralls, Codecov) - cobertura de testes


Principais Ferramentas de Coleta de Dados

A fonte é onde o dado reside; a ferramenta de coleta é o que o extrai e o torna analisável.

Categoria	Ferramentas	O que coleta	Atenção à validade
Repositório / processo	PyDriller, GitHub API	Commits, issues, PRs	Causalidade limitada (observacional)
Execução / <i>runtime</i>	Prometheus, <i>profilers</i>	Desempenho, latência	Exige ambiente controlado
Qualidade estática	SonarQube, JaCoCo	Métricas de código	Métrica $\neq$ qualidade real (construto)
Pessoas	Forms, <i>logging</i> de tarefa	Percepção, tempo, erros	Viés de auto-relato; ética

Exemplo Aplicado: Medindo Desempenho em Java

Pergunta: a versão B do serviço tem maior *throughput* que a A?



O dado de desempenho só existe enquanto a aplicação roda — por isso a cadeia de instrumentação → coleta → análise.

O que é a Linguagem R?

- Linguagem de programação criada em **1993** por Ross Ihaka e Robert Gentleman na Universidade de Auckland (Nova Zelândia)
- Projetada **especificamente para estatística** e análise de dados, diferente do Python que é de propósito geral
- Gratuita, open-source, mantida pelo **R Core Team**
- Repositório oficial: **CRAN** com >20 k pacotes especializados
- Amplamente adotada em **pesquisa acadêmica**, venues como ESEM e ICSE frequentemente publicam replication packages em R

Por que R em ES empírica?

Testes como Wilcoxon, Kruskal-Wallis e cálculo de Cohen's d / Cliff's δ têm implementações mais maduras e citáveis em R do que em Python.

O pacote **ggplot2** segue a *Grammar of Graphics*, produzindo visualizações prontas para publicação com poucas linhas de código.

Ref.: Wohlin et al. (2012) utilizam R nos exemplos de análise estatística ao longo do livro.

Ferramentas para Análise de Dados - Python

Ecosistema Python

- **pandas / NumPy** - manipulação e operações vetoriais em DataFrames
- **SciPy** - testes estatísticos, otimização e integração numérica
- **statsmodels** - regressão, ANOVA, séries temporais
- **scikit-learn** - aprendizado de máquina e pré-processamento
- **Jupyter Notebook** - ambiente interativo de análise e prototipação

Gratuito e open-source; ecossistema PyPI com >500 k pacotes

Ferramentas para Análise de Dados - R e Outras

Ecosistema R

- **tidyverse** - dplyr (wrangling), ggplot2, tidyr
- **caret** / **mlr3** - pipelines de machine learning
- **lme4** - modelos mistos e hierárquicos
- **RStudio** / **Quarto** - IDE e relatórios reproduzíveis
- **CRAN** - repositório com >20 k pacotes

Gratuito; linguagem projetada para estatística desde 1993

Outras Ferramentas

- **SPSS** (IBM) - análise estatística, interface gráfica; pago
- **Stata** - econometria e ciências sociais; pago
- **KNIME** - fluxos de análise visual; free/Enterprise
- **Orange** - mineração de dados visual; open-source
- **Excel** - análise básica; Microsoft 365

Ferramentas Estatísticas para ES - Python

- **scipy.stats** *gratuito*
Testes de hipóteses (t, Mann-Whitney, Wilcoxon, Kruskal-Wallis), distribuições de probabilidade e correlações.
- **statsmodels** *gratuito*
Regressão linear/logística, ANOVA, ANCOVA e séries temporais (ARIMA).
- **pingouin** *gratuito*
API de alto nível para ES; retorna *effect size*, poder e intervalos de confiança em uma única chamada.

Ferramentas Estatísticas para ES - R e GUI

- **effsize / rstatix**

gratuito

Cohen's d , Cliff's δ , η^2 , Hedges' g :
tamanho de efeito exigido em estudos empíricos.

- **JASP**

gratuito, GUI

Interface gráfica para frequentismo e bayesianismo; ideal para quem não programa.

Por que *effect size* import a em ES?

Um p -valor baixo apenas diz que há diferença.

O **tamanho de efeito** (Cohen's d , Cliff's δ) diz *o quanto* essa diferença importa na prática, essencial para comparar ferramentas e técnicas em experimentos controlados.

Ref.: Wohlin et al. (2012) enfatizam a importância de reportar o tamanho de efeito para avaliar a relevância prática dos resultados em experimentos de ES.

Ferramentas para Visualização de Dados (1/2)

Ferramenta	Vantagens	Desvantagens	Custo
Matplotlib	Controle total; integração nativa com NumPy/pandas	API verbosa; estética pobre por padrão	Gratuito
Seaborn	Estética refinada; API de alto nível sobre Matplotlib	Menos flexível para customizações avançadas	Gratuito
Plotly	Gráficos interativos; exporta HTML; Dash para dashboards	Curva de aprendizado; servidor pago	Free/Pago ^a
ggplot2 (R)	Grammar of Graphics; declarativo e extensível	Curva inicial para quem não usa R	Gratuito

^aPlotly OSS gratuito; Dash Pro a partir de \$29/mês/criador.

Ferramentas para Visualização de Dados (2/2)

Ferramenta	Vantagens	Desvantagens	Custo
Tableau	Drag-and-drop; conectores nativos a BD e nuvem; rápido	Custo elevado; pouco controle programático	Pago ^b
Power BI	Integrado ao ecossistema Microsoft; desktop gratuito	Recursos avançados exigem licença Pro/Premium	Free/Pago ^c
D3.js	Máxima flexibilidade; visualizações únicas na web	Alto esforço; requer JavaScript avançado	Gratuito

^bTableau Standard ~\$15/usuário/mês. ^cPower BI Desktop gratuito; Pro ~R\$130/usuário/mês.

Estatística Descritiva — Conceitos Fundamentais

Resume e organiza os dados de uma amostra (sem inferir sobre a população).

Tendência central

- Média: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ (sensível a outliers)
- Mediana — robusta a outliers/assimetria
- Moda — única válida p/ dados nominais

Dispersão

- Variância: $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$
- Desvio padrão $s = \sqrt{s^2}$
- $IQR = Q_3 - Q_1$ (robusto); $CV = \frac{s}{\bar{x}}$

A escala da variável (nominal, ordinal, intervalar, racional) define quais medidas são válidas.

Forma

- Assimetria (*skewness*) — direção da cauda
- Curtose (*kurtosis*) — peso das caudas

Posição

- Quartis e percentis (ex.: **p95** de latência)
- Escore-z: $z = \frac{x - \bar{x}}{s}$

Visualização: histograma, *boxplot*, *scatter*, Q-Q plot

Estatística Descritiva — Por que importa em ES

- Métricas de software (tempos, defeitos, LOC) são tipicamente **assimétricas à direita**: muitos valores baixos, poucos muito altos.
- Quando **média** $\gg$ **mediana**, reporte **mediana + IQR**.
- *Boxplot* localiza *outliers* — ex.: os “métodos monstro” a refatorar.
- *Sempre visualize*: o **quarteto de Anscombe** mostra dados com resumos idênticos e formas opostas.

Exemplo: complexidade ciclomática

200 métodos analisados:

média = 8,4 mediana = 4 máx = 142

A distância média–mediana revela forte assimetria $\Rightarrow$ usar mediana/IQR e desconfiar de técnicas que assumem normalidade.

Testes Estatísticos — Fundamentos da Inferência

Respondem: o efeito observado na amostra é real na população ou fruto do acaso?

- H_0 (sem efeito) vs. H_1 (há efeito)
- **p -valor**: prob. de um resultado tão extremo supondo H_0 verdadeira (não é a prob. de H_0 !)
- α (ex.: 0,05): se $p < \alpha$, rejeita-se H_0
- **Erro Tipo I** (falso positivo) e **Tipo II** (falso negativo)
- **Poder** = $1 - \beta$: amostras pequenas em ES $\Rightarrow$ alto risco de Tipo II

Boas práticas em ES

Significância $\neq$ relevância. Reporte sempre o **tamanho de efeito** (Cohen's d , Cliff's δ , A_{12}).

Software é assimétrico $\Rightarrow$ **prefira testes não-paramétricos.**

Muitos testes? Corrija (**Bonferroni** / FDR).

Testes Estatísticos — Tabela de Aplicação

Teste	Tipo	Grupos	Quando aplicar (exemplo ES)
t (2 amostras)	Paramétrico	2	Médias de 2 grupos indep. (defeitos: com/sem TDD)
t pareado	Paramétrico	2	Mesmo sujeito antes/depois (tempo pré/pós-treino)
ANOVA <i>one-way</i>	Paramétrico	≥ 3	Médias de 3+ grupos (build em 3 CIs)
Mann-Whitney U	Não-param.	2	Alternativa ao t indep. (latência assimétrica)
Wilcoxon <i>signed-rank</i>	Não-param.	2	Alternativa ao t pareado (pré/pós refatoração)
Kruskal-Wallis	Não-param.	≥ 3	Alternativa à ANOVA (esforço em 3 metodologias)
Qui-quadrado (χ^2)	Não-param.	≥ 2	Catégoricas / contingência (tipo de bug $\times$ módulo)
Pearson / Spearman	Correlação	2	Relação linear / monotônica (complexidade $\times$ defeitos)
Shapiro-Wilk	Normalidade	1	Verificar normalidade antes de teste paramétrico
Levene / Bartlett	Variâncias	≥ 2	Verificar homocedasticidade antes da ANOVA

Roteiro: tipo de variável $\rightarrow$ nº de grupos/estrutura $\rightarrow$ pressupostos $\rightarrow$ teste $\rightarrow$ reportar p + tamanho de efeito.

Regressão e Modelagem — Tipos e Quando Usar

Modela a **forma** da relação entre variáveis para **explicar** e **prever**.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$$

Cada β_j é o efeito de x_j *mantendo os demais constantes* (controla confundidores).

- **Linear simples / múltipla** — resposta numérica (esforço, tempo)
- **Logística** — resposta binária $\Rightarrow$ *predição de defeitos (odds ratio)*
- **Poisson / Binomial Negativa** — contagens (nº de bugs, commits)
- **Modelos mistos (LMM)** — dados hierárquicos / medidas repetidas
- **Séries temporais (ARIMA)** — métricas indexadas no tempo

Regressão — Avaliação, Pressupostos e Armadilhas

Avaliação do modelo

- R^2 e R^2 **ajustado** (compara modelos)
- **RMSE** (pune erros grandes) e **MAE**
- **AIC / BIC** — ajuste $\times$ complexidade

Pressupostos (resíduos)

- Linearidade, independência
- Homocedasticidade, normalidade dos resíduos
- Sem multicolinearidade (**VIF**)

Armadilhas

Overfitting: muitas variáveis $\Rightarrow$ usar **regularização** (Ridge/Lasso/Elastic Net); Lasso ainda faz seleção de variáveis.

Correlação $\neq$ causalidade: modelos observacionais sugerem hipóteses; só o **experimento controlado** comprova causa.

Sempre analisar os resíduos (resíduos vs. ajustados, Q-Q, distância de Cook).

Visão Geral - Categorias de Gráficos


- Comparação
- Tendência Temporal
- Distribuição
- Relação entre Variáveis
- Composição
- Correlação
- Hierarquia
- Fluxo/Processo
- Dados Geográficos
- Multidimensional

Comparação - Gráfico de Barras

- **Objetivo:** comparar valores entre categorias discretas
- **Melhor uso:** poucos grupos (≤ 10), variável numérica
- **Vantagens:** intuitivo, fácil leitura
- **Limitações:** ruim para muitas categorias ou proporções
- **Tipo de dado:** categórico $\times$ numérico
- **Exemplo ES:** comparar a **cobertura de testes (%)** entre os módulos de um sistema (ex.: auth, payment, reporting) para priorizar quais precisam de mais testes unitários antes de um *release*. Cada barra é um módulo; uma linha de meta (ex.: 80%) evidencia rapidamente quem está abaixo do limiar.

Comparação - Gráfico de Barras

Gasto Total da Cota Parlamentar por Partido — 2019




Comparação - Barras Agrupadas

- **Objetivo:** comparar múltiplas séries lado a lado
- **Melhor uso:** até 3–4 séries por grupo
- **Vantagens:** comparação direta entre subgrupos
- **Limitações:** fica denso com muitas séries
- **Tipo de dado:** categórico $\times$ numérico $\times$ grupo
- **Exemplo ES:** comparar a contagem de *code smells* detectados por **duas ferramentas** (SonarQube vs. PMD) em **três versões** consecutivas do sistema. O grupo é a versão; as barras lado a lado são as ferramentas, permitindo ver tanto a evolução por versão quanto a divergência entre analisadores estáticos.

Comparação - Barras Agrupadas

Principais Categorias de Gasto por Partido — 2019




Fonte: Brasil.io — dataset gastos-deputados (captura: 2020-03-14).

Comparação - Barras Empilhadas

- **Objetivo:** mostrar parte de um total por categoria
- **Melhor uso:** quando o total e as partes importam
- **Vantagens:** mostra composição e comparação
- **Limitações:** difícil comparar segmentos do meio
- **Tipo de dado:** categórico $\times$ numérico $\times$ parte
- **Exemplo ES:** mostrar, por **sprint**, a composição dos defeitos encontrados (funcionais, de UI, de *performance*, de segurança). Cada barra é uma sprint; os segmentos empilhados revelam ao mesmo tempo o *total* de defeitos e a *proporção* de cada tipo, expondo se uma categoria está crescendo ao longo das sprints.


Comparação - Barras Empilhadas



Tendência Temporal - Gráfico de Linhas

- **Objetivo:** mostrar evolução de uma variável ao longo do tempo
- **Melhor uso:** dados contínuos com eixo temporal
- **Vantagens:** tendência e padrões visíveis
- **Limitações:** inadequado para dados categóricos
- **Tipo de dado:** temporal $\times$ numérico
- **Exemplo ES:** acompanhar a **evolução semanal da cobertura de testes (%)** do projeto ao longo de um semestre, identificando quedas bruscas logo após o *merge* de grandes *features* (que adicionam código sem testes) e a recuperação após sprints de estabilização.

Tendência Temporal - Gráfico de Linhas




Fonte: COVID-19 Brasil.

Tendência Temporal - Gráfico de Área

- **Objetivo:** igual ao de linhas, mas enfatizando volume
- **Melhor uso:** quando acumulação importa
- **Vantagens:** volume cumulativo evidente
- **Limitações:** sobreposição pode ocultar séries
- **Tipo de dado:** temporal $\times$ numérico
- **Exemplo ES:** visualizar o **acúmulo de LOC** (linhas de código) do projeto a cada *release*, evidenciando o ritmo de expansão da base de código. Em versão empilhada, separar o LOC por camada (frontend, backend, testes) mostra qual parte do sistema mais cresceu entre releases.

Tendência Temporal - Gráfico de Área




Fonte: COVID-19 Brasil.

Tendência Temporal - Série Temporal

- **Objetivo:** análise de padrões, sazonalidade e tendência
- **Melhor uso:** dados com frequência regular (diária, mensal)
- **Vantagens:** decomposição de tendência/sazonalidade
- **Limitações:** requer dados regularmente espaçados
- **Tipo de dado:** temporal indexado
- **Exemplo ES:** analisar a série de **commits diários** de um repositório por 12 meses e decompô-la em *tendência* (crescimento do time e da atividade) e *sazonalidade* (quedas recorrentes em fins de semana e feriados), útil para planejar janelas de deploy e estimar capacidade da equipe.

Tendência Temporal - Série Temporal




Fonte: COVID-19 Brasil.

Distribuição - Histograma

- **Objetivo:** mostrar a distribuição de frequências de uma variável
- **Melhor uso:** variável contínua, grande volume de dados
- **Vantagens:** revela forma, simetria e outliers
- **Limitações:** sensível à largura dos bins
- **Tipo de dado:** numérico contínuo
- **Exemplo ES:** mostrar a distribuição do **tamanho (LOC) das funções** de um sistema, evidenciando a assimetria à direita típica de métricas de software: a maioria das funções é pequena e há uma cauda longa de funções grandes, candidatas naturais a refatoração e a maior densidade de defeitos.

Distribuição - Histograma




Caso de uso do histograma: revelar a FORMA de UMA variável — assimetria, onde os dados se concentram e outliers.
Média > mediana confirma a assimetria à direita.

Distribuição - Boxplot

- **Objetivo:** resumir distribuição com quartis e outliers
- **Melhor uso:** comparar distribuições entre grupos
- **Vantagens:** compacto, evidencia outliers e IQR
- **Limitações:** oculta a forma completa da distribuição
- **Tipo de dado:** numérico (por grupos)
- **Exemplo ES:** comparar a **complexidade ciclomática por módulo** usando boxplots paralelos. Cada caixa é um módulo; os pontos acima do bigode superior destacam *outliers* (métodos com $CC > 15$) que representam risco de manutenção e devem entrar primeiro na fila de refatoração.

Distribuição - Boxplot




Caso de uso do boxplot: COMPARAR distribuições entre GRUPOS de forma compacta (mediana, IQR, amplitude) e destacar outliers — sem precisar de um gráfico por grupo.

Distribuição - Gráfico de Violino

- **Objetivo:** combinar boxplot com densidade da distribuição
- **Melhor uso:** quando a forma da distribuição importa
- **Vantagens:** mais informativo que o boxplot
- **Limitações:** menos intuitivo para leigos
- **Tipo de dado:** numérico (por grupos)
- **Exemplo ES:** comparar a distribuição do **tempo de resolução (*lead time*) de issues por prioridade** (baixa, média, alta, crítica). O violino revela o que o boxplot esconde, p. ex. uma distribuição *bimodal* em issues críticas (umas resolvidas em horas via hotfix, outras travadas por semanas em dependências).

Distribuição - Gráfico de Violino

Nota de corte do PROUNI por curso — gráfico de violino




Fonte: PROUNI 2018 (Ministério da Educação), dados tratados por Álvaro Justen / Brasil.IO

Distribuição - Gráfico de Densidade (KDE)

- **Objetivo:** estimar a função de densidade de probabilidade
- **Melhor uso:** distribuições suaves, múltiplas sobrepostas
- **Vantagens:** suavizado, boa comparação de grupos
- **Limitações:** pode suavizar demais (bandwidth)
- **Tipo de dado:** numérico contínuo
- **Exemplo ES:** sobrepor as curvas de densidade do **mutation score** de uma suíte de testes *antes* e *depois* de adicionar novos casos de teste, comparando visualmente o deslocamento da distribuição para a direita (mais mutantes mortos) e quantificando a melhoria na detecção.

Distribuição - Gráfico de Densidade (KDE)




Fonte: PROUNI 2018 (Ministério da Educação), dados tratados por Álvaro Justen / Brasil.IO

Relação - Gráfico de Dispersão (Scatter Plot)

- **Objetivo:** examinar relação entre duas variáveis numéricas
- **Melhor uso:** identificar correlação, clusters, outliers
- **Vantagens:** revela padrões não lineares
- **Limitações:** overplotting com muitos pontos
- **Tipo de dado:** numérico $\times$ numérico
- **Exemplo ES:** investigar a correlação entre o **tamanho (LOC)** e o **número de defeitos** reportados por classe. Cada ponto é uma classe; o gráfico identifica *clusters* de classes grandes e propensas a bugs (canto superior direito) e *outliers* (classes pequenas com muitos defeitos), sustentando hipóteses sobre o impacto do tamanho na qualidade.
- **Dataset:** Gastos dos deputados (2020)

Relação - Gráfico de Dispersão (Scatter Plot)




Dataset: Gastos dos deputados (2020)

Relação - Gráfico de Bolhas (Bubble Chart)

- **Objetivo:** scatter com 3ª dimensão codificada no tamanho da bolha
- **Melhor uso:** 3 variáveis numéricas simultâneas
- **Vantagens:** informação extra sem eixo adicional
- **Limitações:** área de bolha pode enganar percepção
- **Tipo de dado:** numérico $\times$ numérico $\times$ numérico
- **Exemplo ES:** relacionar **complexidade ciclomática** (eixo x) e **número de defeitos** (eixo y), com o **tamanho da bolha** representando o LOC do módulo. Módulos grandes, complexos e bugados aparecem como bolhas grandes no canto superior direito, virando alvo prioritário de refatoração; bolhas pequenas próximas à origem são saudáveis.
- **Dataset:** Gastos dos deputados (2020)

Relação - Gráfico de Bolhas (Bubble Chart)




Dataset: Gastos dos deputados (2020)

Relação - Heatmap

- **Objetivo:** representar valores em uma grade por cor
- **Melhor uso:** matrizes densas de dados numéricos
- **Vantagens:** padrões visíveis em grandes matrizes
- **Limitações:** escolha de paleta afeta interpretação
- **Tipo de dado:** numérico em grade 2D
- **Exemplo ES:** mapear a **atividade de commits da equipe por dia da semana** (eixo x) e **hora do dia** (eixo y). As células mais quentes revelam padrões de trabalho e horários de pico de integração (útil para evitar deploys arriscados em janelas de alta atividade e para discutir saúde do time, ex. commits frequentes de madrugada).
- **Dataset:** Gastos dos deputados (2020)

Relação - Heatmap



Dataset: Gastos dos deputados (2020)


Composição - Gráfico de Pizza

- **Objetivo:** mostrar proporção de partes em relação ao todo
- **Melhor uso:** poucas categorias (≤ 5), diferenças grandes
- **Vantagens:** familiar e intuitivo
- **Limitações:** difícil comparar fatias semelhantes
- **Tipo de dado:** categórico proporcional
- **Exemplo ES:** mostrar a **proporção dos tipos de defeito** (lógica, UI, integração, *performance*) encontrados em um *release*, destacando a categoria dominante. Útil em retrospectivas para responder “onde nossos bugs mais aparecem?”, desde que haja poucas fatias bem distintas.

Composição - Gráfico de Pizza

Composição das Origens Linguísticas

Top 100 nomes — 6 origens + Outros



Total: 74,935,894 pessoas

Origem

- Hebraico
- Latim
- Germânico
- Grego
- Italiano
- Outros
- Inglês


Dados: brasil.io/dataset/genero-nomes/nomes — Classificação de gênero em nomes brasileiros com base no CENSO 2010 | Fonte original: IBGE
Origem dos nomes: behindthename.com

Composição - Donut Chart

- **Objetivo:** variação do pizza com espaço central para métrica
- **Melhor uso:** uma métrica destacada no centro
- **Vantagens:** espaço central aproveitável
- **Limitações:** mesmas limitações do pizza
- **Tipo de dado:** categórico proporcional
- **Exemplo ES:** exibir a **distribuição de bugs por severidade** (*blocker*, crítico, maior, menor) com o **número total de bugs** em destaque no centro do anel. Em um *dashboard* de QA, o centro entrega o KPI principal de relance e o anel detalha sua composição.

Composição - Donut Chart

Análise de Fluidez de Gênero: Nomes Unissex no Brasil



Fonte: Classificação de gênero em nomes brasileiros, com base em dados do CENSO de 2010.

Disponível em: <https://brasil.io/dataset/genero-nomes/nomes/>

Fonte original: Instituto Brasileiro de Geografia e Estatística (IBGE)


Composição - Treemap

- **Objetivo:** mostrar hierarquia e proporção por área retangular
- **Melhor uso:** muitas categorias hierárquicas
- **Vantagens:** escala bem para muitas categorias
- **Limitações:** difícil comparar áreas semelhantes
- **Tipo de dado:** hierárquico $\times$ numérico
- **Exemplo ES:** visualizar a **distribuição de LOC por pacote/classe** de um sistema. A área de cada retângulo identifica de imediato os pacotes mais volumosos (e o nível de aninhamento mostra a hierarquia), ajudando a localizar onde está concentrada a complexidade e por onde começar uma modularização.

Composição - Treemap

Treemap dos Nomes Brasileiros — Origem → Nome

Tamanho = Frequência Total | Cor = Proporção de Gênero (RdBu, midpoint = 0.5)




Dados: brasil2010/genero-nome/nomes — Classificação de gênero em nomes brasileiros com base no CENSO 2010 | Fonte original: IBGE
Origem dos nomes: brasil2010.ibge.gov.br

Correlação - Matriz de Correlação

- **Objetivo:** exibir coeficientes de correlação entre pares de variáveis
- **Melhor uso:** análise exploratória multivariada
- **Vantagens:** visão geral rápida de relações
- **Limitações:** não indica causalidade; correlação linear apenas
- **Tipo de dado:** numérico multivariado
- **Exemplo ES:** cruzar as **métricas CK** (WMC, DIT, CBO, LCOM, RFC) com a **densidade de defeitos** por classe para descobrir quais métricas de acoplamento/coesão mais se associam a bugs, orientando a seleção de *features* antes de um modelo de predição de defeitos.
- **Variáveis (slide):** casos confirmados, óbitos, recuperados, população, densidade

Correlação - Matriz de Correlação





Fonte: COVID-19 Brasil (Secretarias de Saúde).

Correlação - Heatmap de Correlação

- **Objetivo:** visualizar correlação por cores em uma matriz
- **Melhor uso:** descobrir padrões e clusters entre variáveis
- **Vantagens:** muito mais intuitivo que tabelas numéricas
- **Limitações:** não substitui análise de causalidade
- **Exemplo ES:** colorir a matriz de correlação entre métricas de código (LOC, CC, WMC, CBO) para **detectar multicolinearidade** antes de uma regressão de predição de defeitos: blocos de células intensamente vermelhas sinalizam variáveis redundantes que devem ser combinadas ou removidas (cf. VIF).

Correlação - Heatmap de Correlação




Fonte: COVID-19 Brasil com variáveis agregadas por município.

Hierarquia - Sunburst

- **Objetivo:** mostrar hierarquia e proporção de cada nível em anéis concêntricos
- **Melhor uso:** dados hierárquicos com parte/todo (categorias e subcategorias)
- **Vantagens:** compacto; revela composição em vários níveis de uma só vez
- **Limitações:** difícil de ler com muitos níveis ou fatias pequenas
- **Tipo de dado:** hierárquico com valor quantitativo
- **Exemplo ES:** representar a **distribuição de chamadas de API** em uma arquitetura de microsserviços por *serviço* → *endpoint* → *método HTTP*. O anel interno mostra quais serviços concentram tráfego e os anéis externos detalham os endpoints/métodos mais acionados (útil para priorizar otimização e *rate limiting*).

Hierarquia - Sunburst

PROUNI 2018 — Bolsas por grau e curso




Anel interno: grau acadêmico • Anel externo: cursos (Top 6 + Outros) • Tamanho = nº de bolsas

Hierarquia - Organograma

- **Objetivo:** representar estrutura hierárquica de entidades
- **Melhor uso:** árvores com relações pai-filho claras
- **Vantagens:** estrutura de dependência muito legível
- **Limitações:** cresce rapidamente; difícil visualizar grafos
- **Tipo de dado:** relacional hierárquico
- **Exemplo ES:** representar a **árvore de pacotes/módulos** de um sistema em camadas (app → service → repository), evidenciando os módulos centrais dos quais muitos outros dependem, candidatos a maior cobertura de testes por serem pontos únicos de falha.

Hierarquia - Organograma

Hierarquia de Módulos — Sistema E-Commerce




Fonte: API IBGE.

- **Objetivo:** mostrar o fluxo e o volume transferido entre etapas (largura = magnitude)
- **Melhor uso:** fluxos com quantidade; evidencia gargalos e caminhos dominantes
- **Limitações:** fica ilegível com muitos nós ou cruzamentos
- **Tipo de dado:** fluxo origem → destino com peso
- **Exemplo ES:** representar o **fluxo de issues entre estados do workflow** (*aberta* → *em progresso* → *review* → *fechada*), com a largura das faixas indicando o volume. Faixas que “voltam” para estados anteriores (ex.: *review* → *em progresso*) quantificam retrabalho e revelam o *review* como gargalo do processo.

Fluxo/Processo - Sankey

PROUNI 2018 — Fluxo de bolsas: grau → modalidade → tipo




Largura da faixa = nº de bolsas • Total: 242,9 mil bolsas

Fluxo/Processo - Fluxograma

- **Objetivo:** representar sequência de etapas e decisões
- **Melhor uso:** processos com lógica de controle
- **Vantagens:** comunicação universal de fluxos
- **Limitações:** sem dimensão quantitativa
- **Tipo de dado:** qualitativo sequencial
- **Exemplo ES:** modelar o **processo de *code review* de um Pull Request**: abertura → *CI* → revisão → *decisão* (aprovar / solicitar mudanças) → *merge*. Os losangos de decisão tornam explícitos os pontos onde o PR pode voltar ao autor, documentando a política de integração da equipe para novos membros.

Fluxo/Processo - Fluxograma

Fluxograma – Processo de Code Review em PRs



Fonte: PROUNI.

Dados Geográficos - Mapas

- **Objetivo:** situar dados em contexto geoespacial
- **Melhor uso:** quando localização é variável relevante
- **Vantagens:** contexto geográfico imediato
- **Limitações:** requer dados georeferenciados
- **Tipo de dado:** geoespacial
- **Exemplo ES:** situar geograficamente os **contribuidores de um projeto *open source*** (a partir do perfil/localização no GitHub) para entender a distribuição global da comunidade e os *fusos horários* envolvidos, informação que impacta o planejamento de revisões assíncronas e janelas de *release*.

Dados Geográficos - Mapas




Fonte: IBGE (2004).

Dados Geográficos - Choropleth

- **Objetivo:** colorir regiões geográficas por valor de variável
- **Melhor uso:** comparação regional de métricas agregadas
- **Vantagens:** padrões regionais visíveis rapidamente
- **Limitações:** distorção por área de região
- **Tipo de dado:** geoespacial $\times$ numérico
- **Exemplo ES:** colorir países pelo **número de repositórios públicos per capita** (ou densidade de startups de software) para comparar a intensidade de atividade de desenvolvimento entre regiões. A normalização *per capita* evita que países populosos dominem o mapa apenas por tamanho.

Dados Geográficos - Choropleth




Fonte: IBGE (2022).

Multidimensional - Gráfico de Radar (Spider)

- **Objetivo:** comparar múltiplas variáveis em eixos radiais
- **Melhor uso:** perfis de desempenho com 5–10 métricas
- **Vantagens:** visão holística de pontos fortes/fracos
- **Limitações:** área pode enganar; ordem dos eixos importa
- **Tipo de dado:** numérico multivariado
- **Exemplo ES:** comparar o **perfil de qualidade de dois módulos** em métricas CK normalizadas (WMC, DIT, NOC, CBO, RFC, LCOM) sobrepostas no mesmo radar. O polígono de cada módulo revela de relance seus pontos fortes e fracos, ex.: um módulo coeso mas muito acoplado “puxa” o eixo CBO, sugerindo redução de dependências.
- **Dataset (slide):** Gastos dos deputados (cota_parlamentar)

Multidimensional - Gráfico de Radar (Spider)

Gráfico de Radar — Perfil de Gastos Parlamentares por Partido (2019)




Multidimensional - Parallel Coordinates

- **Objetivo:** visualizar instâncias em múltiplos eixos paralelos
- **Melhor uso:** análise de clusters e outliers multivariados
- **Vantagens:** escala para muitas dimensões
- **Limitações:** overplotting com muitos pontos
- **Tipo de dado:** numérico multivariado (alta dimensão)
- **Exemplo ES:** comparar dezenas de **classes em múltiplas métricas simultâneas** (LOC, CC, CBO, LCOM, fan-in, fan-out), cada classe virando uma linha que cruza todos os eixos. Linhas que se destacam em quase todos os eixos identificam *outliers* (classes problemáticas) e feixes paralelos revelam *clusters* de classes com perfil semelhante.
- **Dataset (slide):** Gastos dos deputados (cota_parlamentar)

Multidimensional - Parallel Coordinates

Coordenadas Paralelas — Gastos Parlamentares por Partido — 2019 (R\$ milhões, escala independente por eixo)



Dataset: Gastos dos deputados (cota_parlamentar)

Outros Gráficos - Visão Geral


Gráficos adicionais com forte aderência a **dados de processo e qualidade** em Engenharia de Software:

- **Gráfico de Pareto** - prioriza causas de defeito (princípio 80/20)
- **Burndown / Burnup** - progresso de sprint em métodos ágeis
- **Cumulative Flow Diagram (CFD)** - WIP e *lead time* no Kanban
- **Grafo de Dependências (Network)** - relações não hierárquicas (call graph)
- **Control Chart (SPC)** - estabilidade estatística de um processo

Gráfico de Pareto

- **Objetivo:** ordenar causas por frequência e sobrepor a % acumulada
- **Melhor uso:** priorização de causas-raiz (princípio de Pareto, 80/20)
- **Vantagens:** mostra de imediato as “poucas vitais” vs. “muitas triviais”
- **Limitações:** assume categorias bem definidas; só frequência/contagem
- **Tipo de dado:** categórico $\times$ numérico (+ linha acumulada)
- **Exemplo ES:** ordenar os **tipos de causa-raiz de defeitos** (validação de entrada, concorrência, integração, configuração. . .) por contagem. A linha acumulada evidencia que $\sim 80\%$ dos bugs vêm de poucas causas, direcionando o esforço de QA para onde mais reduz retrabalho.

Gráfico de Pareto




Fonte dos dados: GitHub REST API — pandas-dev/pandas (448 issues) · Acesso: 2026-06-15

Técnica/Referência: Juran (1951); Boehm & Basili, "Software Defect Reduction Top 10 List", IEEE Computer, 2001

Burndown / Burnup

- **Objetivo:** acompanhar trabalho restante (burndown) ou concluído (burnup) no tempo
- **Melhor uso:** controle de progresso de sprint/release em métodos ágeis
- **Vantagens:** compara ritmo real vs. linha ideal; antecipa atrasos
- **Limitações:** sensível a mudanças de escopo (o burnup trata melhor isso)
- **Tipo de dado:** temporal $\times$ numérico (story points / tarefas)
- **Exemplo ES:** traçar os **story points restantes** de uma sprint ao longo dos dias contra a linha ideal de queda. Um burndown que “empaca” no meio sinaliza impedimentos; o burnup adiciona uma linha de escopo total que expõe *scope creep* durante a sprint.

Burndown / Burnup




Nota: contagem de issues (GitHub não tem story points); para a versão em story points, use o dataset TAWOS (Jira).

*Fonte dos dados: GitHub REST API — pandas-dev/pandas (448 issues) · Acesso: 2026-06-15
Técnica/Referência: Cohn, "Agile Estimating and Planning", 2005; Scrum Guide (Schwaber & Sutherland)*

Cumulative Flow Diagram (CFD)

- **Objetivo:** mostrar a quantidade de itens em cada estado do fluxo ao longo do tempo
- **Melhor uso:** diagnosticar WIP, *lead time* e gargalos em Kanban
- **Vantagens:** faixas que se alargam revelam acúmulo de trabalho em um estado
- **Limitações:** exige histórico consistente de transições de estado
- **Tipo de dado:** temporal $\times$ contagem por estado (área empilhada)
- **Exemplo ES:** empilhar a contagem de itens em *To Do*, *Doing* e *Done* dia a dia. A distância vertical entre as bordas estima o *WIP* e o *lead time*; uma faixa de *Doing* que cresce continuamente denuncia um gargalo no desenvolvimento ou no *review*.

Cumulative Flow Diagram (CFD)




Fonte dos dados: GitHub REST API — pandas-dev/pandas (448 issues) · Acesso: 2026-06-15
Técnica/Referência: Anderson, "Kanban", 2010; Vacanti, "Actionable Agile Metrics for Predictability", 2015

Grafo de Dependências (Network)

- **Objetivo:** representar entidades (nós) e suas relações (arestas) não hierárquicas
- **Melhor uso:** dependências entre módulos, *call graphs*, redes de coautoria
- **Vantagens:** revela nós centrais, ciclos e componentes isolados
- **Limitações:** vira “prato de espaguete” com muitos nós; exige layout cuidadoso
- **Tipo de dado:** relacional (grafo dirigido ou não)
- **Exemplo ES:** desenhar o **grafo de dependências entre pacotes** de um sistema, dimensionando os nós por *fan-in*. Nós muito conectados são pontos críticos de acoplamento; *ciclos* entre pacotes indicam violação de camadas e candidatos a refatoração arquitetural.

Grafo de Dependências (Network)

Grafo de Dependências — raiz: flask (10 nós, 11 arestas)



Tamanho do nó $\propto$ nº de dependentes (in-degree).


Fonte dos dados: PyPI JSON API — pacote-raiz 'flask' (profundidade 2) · Acesso: 2026-06-15

Técnica/Referência: Kikas et al., "Structure and evolution of package dependency networks", MSR 2017

Control Chart (SPC)

- **Objetivo:** monitorar uma métrica no tempo com linha central e limites de controle
- **Melhor uso:** avaliar se um processo está sob controle estatístico
- **Vantagens:** distingue variação comum (ruído) de causa especial (sinal)
- **Limitações:** pressupõe processo estável; sensível à escolha dos limites
- **Tipo de dado:** temporal $\times$ numérico (+ LSC/LIC)
- **Exemplo ES:** acompanhar a **taxa de defeitos por release** (ou o *lead time* de issues) com limites de $\pm 3\sigma$. Pontos fora dos limites ou padrões não aleatórios sinalizam uma *causa especial* (ex.: uma mudança de processo ou um release problemático) que merece investigação, em vez de reagir a flutuações normais.

Control Chart (SPC)



Fonte dos dados: GitHub REST API — pandas-dev/pandas (448 issues) · Acesso: 2026-06-15
Técnica/Referência: Florac & Carleton, "Measuring the Software Process: SPC for SPI", SEI, 1999; Montgomery

O grafico errado esconde a dor do usuario

Cenario

Uma plataforma de e-commerce monitora a API de checkout, o endpoint mais critico do sistema. Com a Black Friday se aproximando, o time precisa decidir se e necessario otimizar o servico antes do pico de trafego.

Endpoint monitorado
POST /api/checkout

Volume diario
~**10k** requisicoes

SLA contratado
<**500 ms** de resposta


A pergunta do time

"Nossa API esta dentro do SLA de 500 ms esta semana. Precisamos realmente otimizar antes da Black Friday?"

O engenheiro abre o dashboard e analisa as **medias diarias de latencia**. O numero parece tranquilizador...

O grafico **errado** – Barras de media diaria

O que o time viu: medias diarias de latencia, todas bem abaixo do SLA.



Por que o grafico de medias **nao e suficiente**

O problema da media em metricas de latencia


A media e um unico numero que resume 10.000 experiencias diferentes e **absorve outliers silenciosamente**.

- Usa **apenas a media diaria**: um valor que colapsa toda a distribuicao em um ponto.
- Sensivel a outliers e os **absorve sem sinal visivel** no grafico de barras.
- **Nao revela como os valores estao distribuidos**: se todos estao proximos da media ou se ha grupos extremos.
- **Nao distingue** “todos bem” de “maioria bem, alguns sofrendo muito”.
- **Impossivel calcular P95/P99** a partir de medias agregadas.

Regra: nunca monitore latencia de sistemas apenas pela media. Use **percentis (P95, P99)** como KPIs primarios (*Google SRE Book*).

O grafico certo – Histograma de distribuicao

Histograma revela: distribuicao **bimodal** – dois grupos com experiencias radicalmente diferentes (10.000 requisicoes, segunda-feira).



O grafico certo – Leitura dos Percentis

Os **percentis** revelam o que a media escondia: enquanto a maioria e rapida, um grupo significativo sofre latencias inaceitaveis.

P50	P75	P90	P95 (!!)	P99
105 ms	148 ms	182 ms	1,85 s	2,7 s
mediana			500 usu/dia	100 usu/dia

95% dos usuarios

Checkout em menos de 200 ms – experiencia excelente.

5% dos usuarios (P95-P99)

Esperam de 1,85 s a 2,7 s – muito acima do SLA. Sao **500 pessoas por dia** sendo prejudicadas.

O que o histograma revela – e o grafico errado escondia

Descoberta: distribuicao bimodal

Dois grupos com experiencias **radicalmente diferentes** coexistem no mesmo sistema. A media apagava completamente essa diferenca.

- **9.500 usuarios (95%)** concluem o checkout em menos de 200 ms – experiencia excelente.
- **500 usuarios/dia (5%)** esperam entre 1,5s e 3s – acima do toleravel e do SLA real.
- O **P95 salta de ~ 180 ms para 1,85 s**: um abismo que a media de 200 ms simplesmente absorvia.
- Na Black Friday (10 $\times$ o volume), os 500 afetados viram **5.000 usuarios/dia** – crise publica evitavel.
- A media de ~ 200 ms e matematicamente correta, mas **estatisticamente enganosa** nesse contexto.

Comparativo: barras de media vs. histograma

Barras – medias

(errado)

- ✓ Tendencias diarias e semanais
- ✓ Comparacao rapida entre periodos
- ✓ Facil de explicar a stakeholders
- ✗ Oculta a distribuicao real
- ✗ Mascara grupos de usuarios afetados
- ✗ Nao detecta distribuicao bimodal
- ✗ Impossivel calcular P95/P99

Histograma – distribuicao

(certo)

- ✓ Revela grupos ocultos de usuarios
- ✓ Base para P50, P95, P99
- ✓ Detecta bimodalidade e anomalias
- ✓ Guia otimizacoes com precisao
- ✗ Requer mais contexto para leitura
- ✗ Nao mostra evolucao temporal

*“A media **mente** quando a distribuicao nao e normal.”*

*Use histogramas e percentis para revelar
o que a media silencia.*

Síntese - Escolhendo o Gráfico Certo

Objetivo	Gráfico Recomendado
Comparar categorias	Barras, Barras Agrupadas
Evolução ao longo do tempo	Linhas, Série Temporal
Ver distribuição	Histograma, Boxplot, Violino
Relação entre variáveis	Scatter, Bolhas
Mostrar proporção	Pizza, Treemap
Correlação múltipla	Heatmap de Correlação
Fluxo de processo	Sankey, Fluxograma
Comparar perfis (multivariado)	Radar, Parallel Coordinates
Priorizar causas (80/20)	Pareto
Progresso de sprint (ágil)	Burndown / Burnup
Fluxo de trabalho / WIP	Cumulative Flow Diagram
Dependências / acoplamento	Grafo (Network)
Estabilidade de processo	Control Chart (SPC)

Referências I

- [1] WOHLIN, C. et al. *Experimentation in Software Engineering*. Springer, 2012.
- [2] KITCHENHAM, B. *Guidelines for performing Systematic Literature Reviews in Software Engineering*. EBSE, 2007.
- [3] Datylon. *Types of Charts and Graphs*. <https://www.datylon.com/blog/types-of-charts-graphs-examples-data-visualization>
- [4] *From Data to Viz*. <https://www.data-to-viz.com>
- [5] IBGE — Instituto Brasileiro de Geografia e Estatística. *Censo Demográfico 2022 e API SIDRA* (saneamento, renda, malhas territoriais). <https://sidra.ibge.gov.br>
- [6] DATASUS — Ministério da Saúde. *Informações de Saúde (TabNet)*. <https://datasus.saude.gov.br>

Referências II

- [7] MEC/INEP. *PROUNI — Programa Universidade para Todos: Dados Abertos* (bolsas por grau, modalidade e curso). <https://dadosabertos.mec.gov.br>
- [8] Brasil.IO. *Dataset gastos-deputados / cota parlamentar* (captura: 2020-03-14). <https://brasil.io>
- [9] COVID-19 Brasil — Secretarias Estaduais de Saúde (agregado via Brasil.IO). *Casos, óbitos e recuperados por município*. <https://brasil.io/dataset/covid19>
- [10] GitHub. *GitHub REST API* — issues, labels e milestones (Pareto, Burndown/Burnup, CFD, Control Chart). <https://docs.github.com/rest>
- [11] PyPI — Python Package Index. *JSON API* — metadados e dependências de pacotes (Grafo de Dependências). <https://pypi.org>

Obrigado!

Dúvidas?

Grupo 1 - PUC Minas · Prof. Danilo Maia · 2025